

Couchbase Developer

Eine Dokumenten-orientierte Datenbank

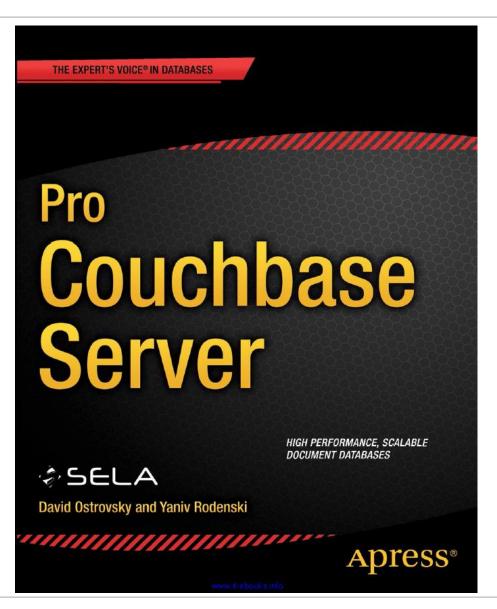
Einige Hinweise



- Die in diesem Seminar verwendete Werkzeuge und Frameworks sind Open Source
 - LPGL Lizenzmodell
- Dokumentation und Ressourcen stehen auch im Internet zur Verfügung
 - https://apacheignite.readme.io/docs/what-is-ignite

Literatur und Quellen







Couchbase architectural advantages

Inhalt



NoSQL: Eine Kurzeinführung	6
Apache Ignite: Eine Übersicht	41
Einsatzbereiche von Apache Ignite	57
Das memory Grid	69
Anwendungen	89
Produktionsumgebung	102



1

NOSQL: EINE KURZEINFÜHRUNG



BIG & FAST DATA

Was ist "Big"?



- Definitionsversuche:
 - Physikalisch
 - Terabyte
 - System
 - Übersteigt den Bedarf eines normalen Speichermediums
 - Technisch
 - Datenverarbeitung beginnt, auf Grund der Größe Probleme zu bereiten
- Allerdings:
 - Keine wirklich eindeutige Definition erkennbar
 - Grenzen können sich verschieben

Wo treten Big Datas auf?



- Völlig verschiedene Bereiche:
 - DNS-Server f
 ür Internet
 - Indizierung von Web Seiten für Suchmaschinen
 - Google
 - Monitoring von Seitenzugriffen, aber auch Metrik-Informationen in großen Server-Systemen
 - Content Management und Waren-Systeme
 - Amazon
 - Social Media
 - Facebook



CLUSTERING

Cluster oder Grid?



- Bei einem Cluster werden die Anwendungen auf identischen Servern betrieben
 - Betriebssystem
 - Laufzeitumgebungen
 - jeweils identische Versionen
- Ein Grid realisiert Anwendungen auf potenziell inhomogenen Rechnern
- Die Unterscheidung zwischen Grid und Cluster ist häufig fließend und deshalb nicht wirklich relevant
 - Im Folgenden wird einheitlich von Clustern gesprochen

Cluster-Strategien

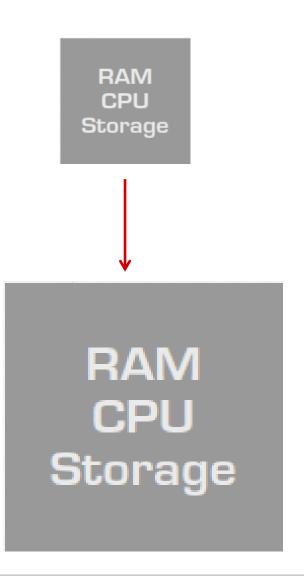


- Zur Ablage und Auswertung von Daten sind selbst m\u00e4chtige Server-Maschinen auf Dauer \u00fcberfordert
- Die Datenhaltung wird deshalb auf mehrere Server verteilt
- Die Lastverteilung übernimmt ein simpler Load Balancer oder ein komplexer "Master"
 - Aus Client-Sicht heraus tritt der Cluster damit immer noch als eine Einheit auf
- Im Optimum ist der Cluster damit eine quasi unendliche Datensenke mit beliebige skalierbarer Rechnerkapazität
 - Damit eine Vorstufe zur "Cloud"

Vertikale Skalierbarkeit



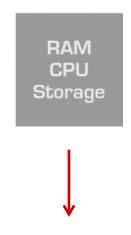
- Grenzen sind klar definiert
 - Kosten
 - Aktuelle Hardware-Grenzen
 - Anforderungen an Ausfallsicherheit



Horizontale Skalierbarkeit



- Grenzen
 - Ausfallsicherheit fordert Replikation über Netzwerk
 - System-Administration und Überwachung



RAM CPU Storage RAM CPU Storage

RAM CPU Storage RAM CPU Storage RAM CPU Storage

RAM CPU Storage



DAS CAP-THEOREM

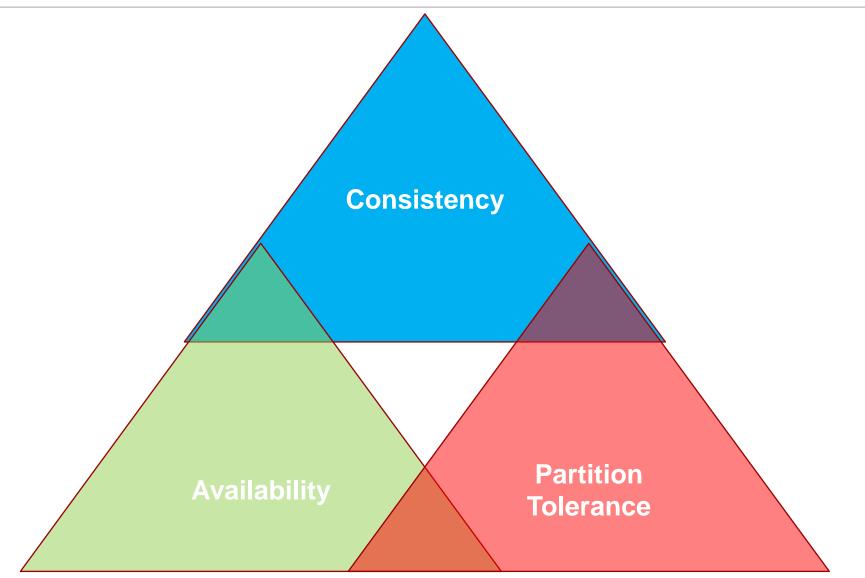
Begriffe



- Consistency
 - Alle Knoten haben jederzeit den selben Informationsstand
- Availability
 - Jeder Client bekommt garantiert Antwort
 - Solange zumindest ein Knoten im Cluster läuft
- Partition Tolerance
 - Das System toleriert
 - Den Ausfall von Knoten
 - Den Ausfall des Netzwerks zwischen Knoten

Keine gemeinsame Schnittmenge!







ANALYSE VON BIG DATA

Analyse von Big Datas



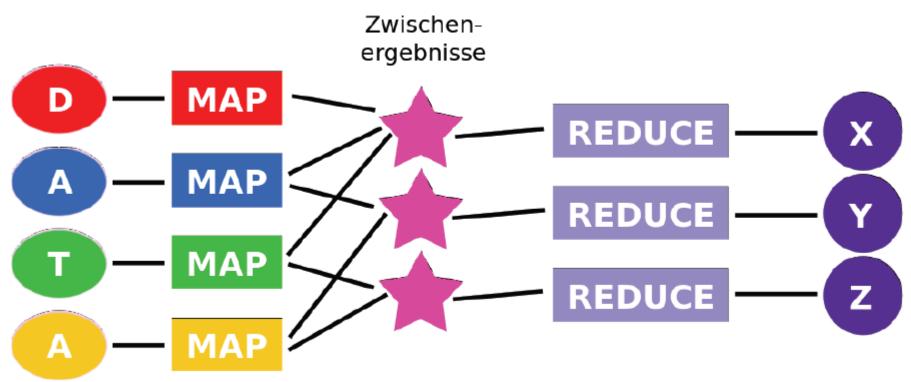
- Verlangt "neue" Algorithmen
 - Aufteilung in Jobs
 - Diese werden parallelisiert
 - Operieren auf einem verteilten Datenbestand
- Alle genannten Unternehmen haben in den letzten 10 Jahren Algorithmen entwickelt bzw. eingesetzt
 - Und "netterweise" der Open Source Community zur Verfügung gestellt
- Fast Data
 - Schneller Zugriff auf Daten-Selektionen
 - Schnelle Umsetzung neuer Abfrage-Anforderungen

Beispiel: MapReduce



- Bahnbrechende Entwicklung
 - Idee wird Google zugeschrieben
- Grundsätzliche Arbeitsweise
 - Operiert auf Mengen (Maps)
 - In einem ersten Schritt werden die Daten der Map in einer neuen Map aufbereitet
 - Diese wird in einem oder mehreren Reduce-Schritten zur Ergebnis-Struktur zusammengefasst





Quelle: http://de.wikipedia.org



TRANSAKTIONALITÄT

ACID



- Atomar, Consistent, Isolated, Durable
- Features
 - Starke Konsistenz der Daten
 - Transaktionssteuerung
 - Transaction-Isolation
 - Bei Bedarf Zwei-Phasen-Commit
 - Relativ komplexe Entwicklung
- Relationale Datenbanken fokussieren auf ACID-Transkationen

BASE



- Basically Available, Soft State, Eventual Consistency
 - Consistency
 - Alle Knoten haben jederzeit den selben Informationsstand
 - Eventually Consistent
 - Änderungen des Datenbestandes werden zeitlich versetzt an die anderen Knoten propagiert
 - "Eventual" nicht mit "eventuell" übersetzen!
- Features
 - Letzliche Konsistenz
 - Hohe Verfügbarkeit
 - Schnelligkeit
 - Bei Bedarf "Fire-and-forget"
 - Leichtere Entwicklung



WAS IST NOSQL?

NoSQL



- No SQL!
 - Ursprüngliche Bedeutung
 - Etwas dogmatische Ablehnung relationaler Datenbank-Prinzipien
- Not only SQL
 - Schon deutlich abgeschwächt
 - Reduktion auf geeignete Problemstellungen
- No/ Not only relational
 - Der eigentlich richtige Begriff
 - Fokussierung auf die Daten-Modellierung, nicht auf die Abfragesprache



KLASSIFIZIERUNG

Klassifizierung von NoSQL-Produkten



- Key/Value
- Column-orientiert
- Dokumenten-orientiert
- Graphen-orientiert

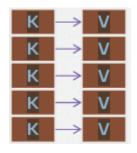
Key/Value



- Ablage von Inhalten (=Value) unter einem eindeutigen Schlüssel (key)
 - Flache Struktur
 - Values werden als Byte-Array betrachtet
- Teilweise Verzicht auf Persistierung der Daten
 - Cache-Systeme
- Auslegung auf eine Vielzahl konkurrierender Zugriffe

Key/Value: Arbeitsweise





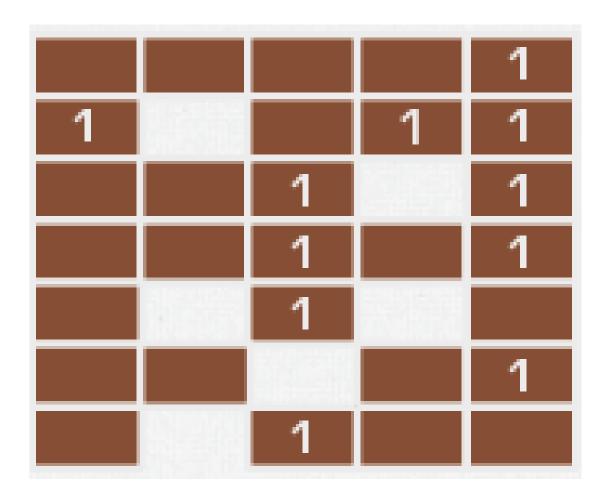
Column-orientiert



- Daten werden in Columns abgelegt
 - Eine Zeile besteht aber nicht zwangsläufig aus allen Columns
- Diese Columns können noch in Gruppen unterteilt werden
 - Vorteilhaft bei einer verteilten Datenhaltung
- Ausrichtung auf wirklich große Datenmengen

Column-orientiert: Arbeitsweise





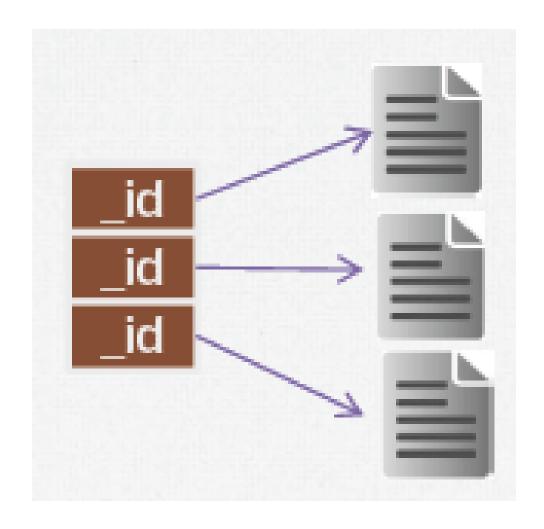
Dokumenten-orientiert



- Ablage der Daten in strukturierten Dokumenten
 - Nicht unbedingt XML!
 - Wesentlich weiter verbreitet ist JSON
 - Bzw. das binäre BSON

Dokumenten-orientiert: Arbeitsweise





Graphen-orientiert



- Ablage der Daten in
 - Knoten
 - Beziehungen
 - Attribute
- Knoten und Beziehungen haben Attribute
- Knoten sind mit Beziehungen verknüpft und umgekehrt
- "Whiteboard-Friendly"
 - "Was Sie auf einem Whiteboard zeichnen können, können Sie in einer Graph-DB ablegen."

Graphen-orientiert: Arbeitsweise







DATENMODELLIERUNG

Statische Typisierung



- Daten werden abstrahiert modelliert
 - Klassenorientierte Programmierung
 - Java, C++/C#, ...
 - Tabellen-Schemata
 - XML-Schema
- Eine Umwandlung von Datentypen erfordert ein Umkopieren
 - "Migration"
- Damit sind Entwicklungszyklen und die Zeiten für die Einführung geänderter Features relativ lang

Dynamische Typisierung



- "Duck Typing": Nur vorhandene Eigenschaften und implementiertes Verhalten zählen
 - "Was gelb ist, quakt und watschelt ist eine Ente"
- Dies ist vorwiegend die Domäne von dynamischen Skript-Sprachen
 - Ruby, Python, JavaScript
- Ein Umkopieren von Daten ist nur noch in Ausnahmefällen notwendig
- Damit wird eine agile Software-Entwicklung unterstützt

Statisch versus Dynamisch



- Was ist…
 - Besser?
 - Richtig?
 - Komfortabel?
- Leider keine pauschale Antwort möglich
 - "Wer lebend den Raum verlässt hat gewonnen"
- Aber:
 - Der Trend der letzten Jahre geht immer mehr Richtung Dynamik



DIE COUCHBASE

1.0.1019 © Javacream Couchbase Developer 40



FEATURES

1.0.1019 © Javacream Couchbase Developer 41

Das Datenbanksystem



- Eine dokumenten-orientierter Key-Value-Store
- Horizontale Skalierung im Ring-Cluster
 - Master-less
 - Admin-less
 - Konfigurierbare Ausfallsicherheit durch Replikation
- Administration und Überwachung durch Web-Konsole
- Distribution

Daten-Organisation



- Ablage der Daten in "Buckets"
 - Entsprechen einer Tabelle
 - Im Objekt-orientierten Sinne einer Tabelle
 - Ein simpler Bucket enspricht einem Key-Value-Store
- Values sind JSON-Strukturen
 - Schema on Read
 - Daten-Modellierung ist damit Dokumenten-orientiert

Daten-Integrität



- Couchbase wird meistens als CP-System betrieben
 - Bei großen Systemen mit mehreren Rechenzentren wird auf AP und damit eine BASE-Architektur umgestellt

Abfrage



- Couchbase-Views
 - Parametrisierte Map-Reduce-Algorithmen
- N1QL
 - Non-First Normal Form Query Language
 - Angelehnt an SQL
 - Keine Unterstützung des vollen SQL-Standards möglich
 - Dafür Ergänzungen, die aus der Dokumenten-Modellierung heraus resultieren



WEITERFÜHRENDE RESSOURCEN

1.0.1019 © Javacream Couchbase Developer 46





Consistent. Elastic. Scalable. Always available. Data storage.

Kelum Senanayake

Artikelsammlung der DZone



